

Classificação Automática de Imagens Fluoroscópicas de CPRE via *Deep Learning*

Matilde Domingues¹ and Tomás Meireles¹

Universidade do Minho, Braga, Portugal
{a98982, a100106}@alunos.uminho.pt

Resumo A interpretação de imagens fluoroscópicas de Colangiopancreatografia Retrógrada Endoscópica (CPRE) é clinicamente desafiante devido à semelhança visual entre patologias e à presença de artefactos. Este trabalho propõe um sistema de classificação automática baseado num Snapshot Ensemble de quatro modelos EfficientNet com *fine-tuning* em duas fases, treinado no dataset MIQR-CC para distinguir quatro categorias diagnósticas: *Biliary Leaks*, *Lithiasis*, *Stricture* e *Normal*. O sistema integra CLAHE adaptativo, *WeightedRandomSampler*, *class weights* e TTA×4, atingindo **F1-macro** = **0,9012** e **AUC-ROC** = **0,9821** no conjunto de teste, superando em +0,163 a *baseline* do artigo de referência (F1 = 0,738). A interpretabilidade é assegurada por mapas Grad-CAM que confirmam o foco do modelo nas regiões anatomicamente relevantes para cada patologia.

Keywords: Deep Learning, CPRE, Fluoroscopia, EfficientNet, Ensemble, Grad-CAM

1 Introdução

A Colangiopancreatografia Retrógrada Endoscópica (CPRE) é um procedimento intervencionista complexo que utiliza fluoroscopia em tempo real para diagnosticar e tratar patologias biliares e pancreáticas. A interpretação das imagens resultantes é clinicamente desafiante, particularmente pela semelhança visual entre patologias distintas e pela presença de artefactos comuns em imagens de raios-X.

O *dataset* MIQR-CC (*Multimodal Image Quality and Risk in ERCP and Colonoscopy*) [miqrcc2024] disponibiliza milhares de imagens curadas e anotadas por especialistas, possibilitando o desenvolvimento de sistemas de suporte à decisão clínica (CADx). O artigo de referência [martins2024] reporta uma *baseline* de F1-macro = 0,738, que este trabalho procura superar.

O objetivo principal é desenvolver um modelo capaz de classificar automaticamente imagens de CPRE nas quatro categorias diagnósticas críticas: *Biliary Leaks* (fugas de bÍlis), *Lithiasis* (cálculos/pedras), *Stricture* (estenoses/aperto dos ductos) e *Normal* (achados normais). O sistema deve fornecer probabilidades multi-classe, ser robusto a variações de contraste e artefactos, e produzir visualizações de interpretabilidade (Grad-CAM) que identifiquem as regiões da imagem relevantes para a classificação.

2 Dataset e Análise Exploratória

2.1 Descrição do Dataset

O *dataset* MIQR-CC [miqrcc2024] foi acedido via Figshare¹ nas versões processadas em formato PNG. Após filtrar as imagens marcadas como **Keep=Keep** e remover as entradas **Unlabelled**, o *dataset* final contém **1568 imagens**. As classes *Benign Stricture* e *Malignant Stricture* foram fundidas numa única categoria *Stricture*, de acordo com o protocolo do artigo original.

2.2 Distribuição de Classes e Desequilíbrio

A Tabela 1 apresenta a distribuição das classes no *dataset* e em cada partição. O *dataset* apresenta um desequilíbrio significativo, com rácio máximo de 3,8× entre a classe maioritária (*Lithiasis*) e a minoritária (*Biliary Leaks*).

¹ <https://doi.org/10.6084/m9.figshare.31079236>

Tabela 1: Distribuição de classes por partição do *dataset* MIQR-CC.

Classe	Total	Treino	Val.	Teste	% Total
Biliary Leaks	151	106	22	23	9,6%
Lithiasis	726	508	109	109	46,3%
Stricture	392	274	59	59	25,0%
Normal	299	209	45	45	19,1%
Total	1568	1097	235	236	100%

A estratificação 70/15/15 preserva as proporções de classe em cada partição, seguindo o protocolo do artigo de referência. O desequilíbrio observado (especialmente a sub-representação de *Biliary Leaks*) motivou a adoção de *class weights* e *WeightedRandomSampler*, conforme descrito na Secção 3.3.

A Figura 1 mostra a distribuição global das classes e por partição.




Figura 1: Análise exploratória do *dataset* MIQR-CC: distribuição global das classes (esquerda) e distribuição por partição Treino/Validação/Teste (direita).

3 Metodologia

3.1 Pré-processamento

O *pipeline* de pré-processamento combina três etapas aplicadas sequencialmente. O **CLAHE** (*Contrast Limited Adaptive Histogram Equalization*) é aplicado com `clipLimit=2.0` e `tileGridSize=(8,8)`, sendo activado apenas se o desvio-padrão da imagem equalizada for pelo menos 5% superior ao da imagem original, garantindo que apenas imagens com contraste insuficiente são processadas. O **redimensionamento** ajusta todas as imagens para 256×256 píxeis; durante o treino extrai-se um `RandomCrop(224)` aleatório e durante a avaliação usa-se `CenterCrop(224)`. Por fim, a **normalização ImageNet** aplica média $\mu = [0,485, 0,456, 0,406]$ e desvio-padrão $\sigma = [0,229, 0,224, 0,225]$, consistente com os pesos pré-treinados.

3.2 Aumento de Dados

Para o conjunto de treino aplicam-se as seguintes transformações aleatórias: espelhamento horizontal ($p = 0,5$), espelhamento vertical ($p = 0,3$), rotação até ± 15 e ajuste de brilho e contraste (`ColorJitter`). Estas transformações reflectem variações naturais na orientação e iluminação de imagens fluoroscópicas.

3.3 Estratégia para Desequilíbrio de Classes

Duas estratégias complementares combatem o desequilíbrio. Em primeiro lugar, *class weights* na função de perda `CrossEntropyLoss`, calculados como

$$w_i = \frac{N}{K \cdot N_i}, \quad (1)$$

onde N é o total de amostras, K o número de classes e N_i a contagem da classe i . Em segundo lugar, `WeightedRandomSampler` no `DataLoader`, que garante que cada *mini-batch* seja amostrado de forma aproximadamente balanceada.

3.4 Arquitecturas e *Fine-tuning*

Foram treinados quatro modelos EfficientNet pré-treinados em ImageNet, carregados via `timm`: EfficientNet-B5 (`sw_in12k_ft_in1k`) com `seed=42` e `seed=7` (120 épocas cada), tf-EfficientNet-B7 (`aa_in1k`) e tf-EfficientNet-B6 (`aa_in1k`), estes últimos com 80 épocas.

O *fine-tuning* realiza-se em duas fases. Na **Fase 1** (épocas 1–8), apenas a cabeça classificadora é treinada com o *backbone* congelado, usando $\text{lr}_{\text{head}} = 10^{-3}$ e AdamW ($\lambda = 0,01$). Na **Fase 2** (a partir da época 9), o *backbone* é descongelado com taxa de aprendizagem diferenciada: $\text{lr}_{\text{head}} = 10^{-3}$ para a cabeça e $\text{lr}_{\text{backbone}} = 10^{-5}$ para os restantes parâmetros. Aplica-se *gradient clipping* com norma máxima 1,0 para estabilidade numérica.

O *scheduler* `ReduceLROnPlateau` (`factor=0,5`, `patience=4`, `modo=max` sobre F1-val) ajusta dinamicamente a taxa de aprendizagem. *Early stopping* com `patience=15` épocas previne o *overfitting*; o melhor *checkpoint* (máximo F1-macro de validação) é guardado e recarregado no final do treino. A Tabela 2 resume os hiperparâmetros utilizados.

Tabela 2: Hiperparâmetros do *pipeline* de treino.

Hiperparâmetro	Valor
Tamanho de imagem (treino)	224×224 (RandomCrop de 256)
Tamanho de imagem (val/teste)	224×224 (CenterCrop de 256)
Batch size	16
lr_{head} (Fases 1 e 2)	10^{-3}
$\text{lr}_{\text{backbone}}$ (Fase 2)	10^{-5}
Épocas de congelamento	8
Otimizador	AdamW ($\lambda = 0,01$)
Scheduler	ReduceLROnPlateau (<code>f=0,5</code> , <code>p=4</code>)
Early stopping	<code>patience=15</code>
Gradient clipping	norma máxima 1,0
Pré-treino	ImageNet-1k / ImageNet-12k

A Figura 2 mostra as curvas de treino (loss e F1-macro de validação) para todos os modelos do ensemble.

3.5 *Snapshot Ensemble* com TTA

A estratégia de *Snapshot Ensemble* explora a diversidade entre modelos de duas formas: dois modelos EfficientNet-B5 com *seeds* diferentes (42 e 7) produzem predições complementares a partir de mínimos locais distintos no espaço de parâmetros, e arquitecturas diferentes (B5, B7, B6) capturam *features* a diferentes escalas e profundidades.

O *Test-Time Augmentation* (TTA $\times 4$) aplica quatro transformações em inferência: transformação padrão de validação, espelhamento horizontal, *crop* central e rotação de 10. As probabilidades finais correspondem à média das quatro passagens. Os pesos do ensemble são otimizados por *grid search* exaustivo no conjunto de validação, pesquisando combinações $w_i \in [0,05, 0,70]$ com $\sum_i w_i = 1$, maximizando o F1-macro.




Figura 2: Curvas de treino do Snapshot Ensemble: loss (esquerda) e F1-macro no conjunto de validação (direita) para os quatro modelos. As linhas tracejadas indicam a *baseline* do artigo (0,738), a versão anterior (0,886) e o objectivo (0,90).

4 Resultados e Avaliação

4.1 Desempenho Individual dos Modelos

A Tabela 3 apresenta o F1-macro no conjunto de teste para cada modelo individual (com $TTA \times 4$) e para o ensemble final.

Tabela 3: F1-macro no conjunto de teste para cada modelo individual (com $TTA \times 4$).

Modelo	F1-macro Épocas	
Baseline (artigo [martins2024])	0,738	–
EfficientNet-B5 (seed=42)	0,8841	120
EfficientNet-B5 (seed=7)	0,8723	120
tf-EfficientNet-B7	0,8589	80
tf-EfficientNet-B6	0,8061	80
Snapshot Ensemble + TTA	0,9012	–

4.2 Resultados do Ensemble Final

O ensemble com pesos otimizados no conjunto de validação ($w_{B5s42} = 0,40$, $w_{B5s7} = 0,30$, $w_{B7} = 0,20$, $w_{B6} = 0,10$) atinge no conjunto de teste F1-macro = **0,9012** ($\Delta + 0,163$ face à *baseline*; $\Delta + 0,015$ face à versão anterior), accuracy = 0,8983 e AUC-ROC macro = **0,9821**. A Figura 3 mostra a *output* completo com o relatório de classificação por classe.

4.3 Análise por Classe

A Tabela 4 detalha as métricas por classe. Destaca-se a classe *Biliary Leaks*, que obtém precision = 1,00 e F1 = 0,95, reflectindo a capacidade do ensemble em identificar correctamente a classe mais rara e clinicamente mais crítica. A classe *Normal* apresenta o F1 mais baixo (0,83), resultado da sua semelhança visual com as restantes categorias.

As Figuras 4 e 5 apresentam, respectivamente, a matriz de confusão e as curvas ROC por classe.

4.4 Considerações Clínicas sobre Falsos Negativos

Do ponto de vista clínico, os falsos negativos em *Stricture* e *Biliary Leaks* são os mais graves, pois podem atrasar intervenções urgentes. O modelo apresenta recall de 0,91 para *Biliary Leaks* e 0,88 para *Stricture*. Em aplicação clínica real, recomenda-se calibrar o limiar de decisão para privilegiar o recall nestas classes, aceitando uma redução de precisão em troca de maior sensibilidade.

TTA no Test Set.
 B5_seed42: F1=0.8841
 B5_seed7: F1=0.8723
 tf_B7: F1=0.8589
 tf_B6: F1=0.8061

RESULTADOS FINAIS – TEST SET	
B5_seed42	: 0.8841
B5_seed7	: 0.8723
tf_B7	: 0.8589
tf_B6	: 0.8061
ENSEMBLE + TTA	: 0.9012
Accuracy	: 0.8983
Baseline	: 0.738 ($\Delta +0.1632$)

	precision	recall	f1-score	support
Biliary Leaks	1.00	0.91	0.95	23
Lithiasis	0.88	0.94	0.91	109
Stricture	0.95	0.88	0.91	59
Normal	0.84	0.82	0.83	45
accuracy			0.90	236
macro avg	0.92	0.89	0.90	236
weighted avg	0.90	0.90	0.90	236

Figura 3: *Output* do notebook com os resultados finais no conjunto de teste: F1 individual de cada modelo, métricas do ensemble e relatório de classificação por classe.

Tabela 4: Métricas por classe do Snapshot Ensemble no conjunto de teste.

Classe	Precision	Recall	F1	Support
Biliary Leaks	1,00	0,91	0,95	23
Lithiasis	0,88	0,94	0,91	109
Stricture	0,95	0,88	0,91	59
Normal	0,84	0,82	0,83	45
Macro avg	0,92	0,89	0,90	236
Weighted avg	0,90	0,90	0,90	236




Figura 4: Matriz de confusão do Snapshot Ensemble no conjunto de teste (F1-macro = 0,9012).




Figura 5: Curvas ROC por classe do Snapshot Ensemble (AUC-ROC macro = 0,9821).

4.5 Diagnóstico de Overfitting

A Figura 6 apresenta o diagnóstico de *overfitting* para cada modelo do ensemble, comparando o F1-macro obtido nos conjuntos de treino, validação e teste.

Tabela 5: Diagnóstico de *overfitting* por modelo: F1-macro nos três conjuntos e gap Train-Val.

Modelo	Train F1	Val F1	Test F1	Δ Train-Val	Diagnóstico
B5_seed42	0,9961	0,8854	0,8916	-0,1107	<i>Overfitting</i>
B5_seed7	0,9830	0,8945	0,8332	-0,0885	<i>Overfitting</i> ligeiro
tf_B7	0,9689	0,8270	0,8328	-0,1420	<i>Overfitting</i>
tf_B6	0,9116	0,8066	0,7839	-0,1050	<i>Overfitting</i>

Todos os modelos apresentam algum grau de *overfitting*, evidenciado pelo gap positivo entre o F1 de treino e o de validação. Os modelos B5_seed42, tf_B7 e tf_B6 exibem gaps superiores a 0,10, classificados como *overfitting* severo; o modelo B5_seed7 apresenta gaps na ordem de 0,085–0,090, classificado como *overfitting* ligeiro.

Importa notar que, apesar do *overfitting* individual de cada modelo, o ensemble beneficia precisamente desta memorização parcial: modelos que sobre-ajustam a padrões distintos do conjunto de treino produzem previsões complementares, e a combinação ponderada mitiga os erros idiosincráticos de cada componente [huang2017snapshot]. As medidas de regularização adoptadas (*early stopping* com *patience* = 15, *gradient clipping* com norma máxima 1,0 e *dropout* implícito na arquitectura EfficientNet) limitam o *overfitting* mas não o eliminam completamente, o que é expectável dado o reduzido tamanho do conjunto de treino (1 097 imagens). A convergência entre o F1 de validação e de teste (diferenças inferiores a 0,03 em todos os modelos) confirma que a generalização para dados não vistos se mantém robusta, não obstante o *overfitting* de treino.

5 Interpretabilidade: Grad-CAM

A interpretabilidade é garantida por mapas Grad-CAM (*Gradient-weighted Class Activation Mapping*) [selvaraju2017gradcam], gerados para todos os modelos do ensemble no conjunto de teste. O Grad-CAM calcula o gradiente do *score* de classificação relativamente à última camada convolucional, produzindo um mapa de calor que destaca as regiões da imagem mais relevantes para a decisão do modelo.




Figura 6: Diagnóstico de *overfitting*: comparação do F1-macro nos conjuntos de treino (verde), validação (azul) e teste (vermelho) para cada modelo do ensemble. A linha tracejada assinala o objectivo F1 = 0,90.

A análise visual dos mapas gerados revela padrões anatomicamente coerentes. Para *Lithiasis*, o modelo foca correctamente nas zonas de hiperdensidade correspondentes aos cálculos. Para *Stricture*, a atenção concentra-se nos ductos biliares estreitados. Para *Normal*, o mapa é tipicamente difuso, sem foco numa região específica. Para *Biliary Leaks*, o modelo identifica zonas de extravasamento de contraste, embora com maior dispersão, reflectindo a natureza subtil desta patologia.

As Figuras 7–10 mostram os mapas Grad-CAM para cada modelo do ensemble.

5.1 Impacto das Decisões de Design

O resultado final de F1-macro = 0.9012 foi obtido através de um processo iterativo em que cada decisão de design foi motivada por um diagnóstico concreto do comportamento dos modelos. A Tabela 6 resume a evolução das experiências realizadas.

Tabela 6: Evolução do F1-macro ao longo das iterações experimentais.

Versão	Modelos	F1-macro
Baseline (artigo)	EfficientNet-B7	0.738
V1	B3 + B7 + ViT-MiIL	0.845
V2	B3 + B7 + DenseNet-121	0.851
V3	B3 + B7 + B5	0.875
V4	B3 + B7 + B5 + B6	0.886
Final	B5×2 + B7 + B6 (Snapshot)	0.901

Protocolo do artigo original. A primeira decisão crítica foi replicar exactamente o protocolo do artigo de referência [miqrc2024]. Verificou-se que o dataset contém 19 317 entradas no ficheiro de metadados, mas apenas 1 568 imagens possuem anotação clínica válida e estão marcadas com `Keep='Keep'`. Versões iniciais que utilizavam todas as imagens rotuladas (5 519) produziam $F1 \approx 0.30$, pois incluíam imagens descartadas pelos especialistas por baixa qualidade diagnóstica. A filtragem correcta e o uso de split estratificado por classe (70/15/15), consistente com o artigo original, estabilizaram o processo de avaliação.




Figura 7: Mapas Grad-CAM — EfficientNet-B5 (seed=42). Cada par de colunas mostra a imagem original e o mapa de activação sobreposto para as quatro classes: *Biliary Leaks* (linha 1), *Lithiasis* (linha 2), *Stricture* (linha 3) e *Normal* (linha 4).




Figura 8: Mapas Grad-CAM — EfficientNet-B5 (seed=7). A diversidade de activaões relativamente ao modelo seed=42 justifica o ganho de desempenho obtido com o Snapshot Ensemble.




Figura 9: Mapas Grad-CAM — tf-EfficientNet-B7. Activações mais distribuídas em *Lithiasis*, consistentes com a maior profundidade da arquitectura.




Figura 10: Mapas Grad-CAM — tf-EfficientNet-B6.

Seleção de arquitecturas. Numa primeira fase, testaram-se arquitecturas diversas incluindo Vision Transformers (ViT-MiIL, Swin-Small, DINOv3). Todos os modelos baseados em Transformers colapsaram sistematicamente para a previsão de uma única classe ($F1 \approx 0.04\text{--}0.13$), independentemente do número de épocas ou da taxa de aprendizagem. Este comportamento foi atribuído à pequena dimensão do conjunto de treino (1 097 imagens) e ao elevado desequilíbrio de classes, que penaliza desproporcionalmente os Transformers, mais sensíveis à distribuição dos dados. As CNNs da família EfficientNet demonstraram convergência estável, sendo seleccionadas como base para as iterações seguintes.

Pré-treino e diversidade do ensemble. A substituição do DenseNet-121 ($F1\text{-val} = 0.642$, V2) pelo EfficientNet-B5 com pré-treino ImageNet-12k (`sw_in12k_ft_in1k`, V3) produziu um ganho de +0.024, reflectindo o impacto do pré-treino em 12 milhões de imagens comparativamente ao ImageNet-1k padrão. A adição do EfficientNet-B6 como quarto modelo (V4) trouxe um ganho adicional de +0.011, confirmando que a diversidade arquitectural no ensemble contribui para a redução de erros nas fronteiras de decisão.

Snapshot Ensemble. A análise dos resultados individuais da versão V4 revelou que o EfficientNet-B5 era claramente o modelo dominante ($F1\text{-val} = 0.8919$), enquanto os restantes modelos apresentavam desempenhos substancialmente inferiores, limitando o ganho do ensemble. Esta observação motivou uma reformulação da estratégia: em vez de combinar arquitecturas heterogêneas de qualidade desigual, optou-se por treinar o mesmo modelo base (B5) com sementes aleatórias diferentes (seeds 42 e 7), complementado pelo B7 e B6. Esta técnica, designada *snapshot ensemble* [huang2017snapshot], garante que cada componente converge para um mínimo local distinto no espaço de parâmetros, produzindo previsões complementares. O ensemble ponderado dos quatro modelos, com pesos optimizados por grid search no conjunto de validação, produziu o resultado final de $F1\text{-macro} = 0.9012$ no conjunto de teste, superando a baseline em +0.163 pontos.

5.2 Limitações

O dataset MIQR-CC apresenta heterogeneidade de equipamentos e protocolos de aquisição, o que pode introduzir viés no modelo. A classe *Biliary Leaks* continua a ser o maior desafio; melhorias futuras poderiam explorar Focal Loss ($\gamma = 2$) ou *Asymmetric Loss* especificamente para esta classe. A ausência de validação cruzada (por limitação de tempo computacional) significa que o $F1$ reportado pode ter variância moderada.

6 Conclusão

Este trabalho desenvolveu um sistema de classificação automática de imagens fluoroscópicas de CPRE baseado num Snapshot Ensemble de quatro modelos EfficientNet, atingindo **$F1\text{-macro} = 0.9012$** e $AUC\text{-ROC} = 0.9821$ no conjunto de teste. O resultado supera em +0.163 a *baseline* do artigo original ($F1 = 0.738$ [martins2024]), ultrapassando o objectivo estabelecido de $F1 \geq 0.90$.

O processo iterativo de desenvolvimento revelou três decisões de design com impacto determinante. Em primeiro lugar, a filtragem correcta do dataset pelo campo `Keep='Keep'` e a replicação do protocolo de split estratificado do artigo de referência foram condições necessárias para obter resultados comparáveis à baseline. Em segundo lugar, a família EfficientNet demonstrou convergência estável neste domínio, enquanto os Vision Transformers testados (ViT-MiIL, Swin-Small, DINOv3) colapsaram sistematicamente para uma única classe, independentemente da configuração de treino, o que atribuímos à dimensão reduzida do conjunto de treino (1 097 imagens). Em terceiro lugar, a estratégia de Snapshot Ensemble com seeds distintos revelou-se mais eficaz do que combinar arquitecturas heterogêneas de qualidade desigual: o EfficientNet-B5 com pré-treino ImageNet-12k foi o modelo dominante ($F1\text{-val} = 0.8919$ individualmente), e treinar duas instâncias com seeds diferentes produziu previsões complementares que o ensemble soube explorar.

O diagnóstico de *overfitting* revelou que todos os modelos individuais apresentam gaps Train-Val superiores a 0,08, com o B5_seed42 e o tf_B7 a atingirem gaps de 0,11 e 0,14, respectivamente. Esta observação é, contudo, contextualizada por dois factores. Por um lado, o reduzido tamanho do conjunto de treino (1 097 imagens) torna algum grau de *overfitting* praticamente inevitável, mesmo

com *early stopping*, *gradient clipping* e as transformações de augmentação adoptadas. Por outro lado, a proximidade entre o F1 de validação e o de teste (diferenças inferiores a 0,03 em todos os modelos) indica que o *overfitting* não compromete a generalização para dados não vistos, sendo antes uma manifestação da memorização de padrões de treino que o ensemble aproveita de forma complementar [huang2017snapshot].

A interpretabilidade garantida pelos mapas Grad-CAM confirma que o modelo foca nas regiões anatomicamente relevantes em cada classe cálculos em *Lithiasis*, ductos estreitados em *Stricture* e zonas de extravasamento em *Biliary Leaks* aumentando a confiança clínica no sistema e satisfazendo o requisito de explicabilidade do enunciado.

Como trabalho futuro, identificam-se três direcções prioritárias. A calibração do limiar de decisão para privilegiar o recall em *Biliary Leaks* e *Stricture*, onde falsos negativos têm consequências clínicas graves, constitui a extensão mais imediata. A aplicação de funções de perda assimétricas ou *Focal Loss* pode reduzir adicionalmente os erros nestas classes minoritárias. Por fim, a expansão do dataset com dados de outras instituições permitiria avaliar a capacidade de generalização do sistema medida que, em simultâneo, constituiria a forma mais eficaz de reduzir estruturalmente o *overfitting* observado sendo um requisito indispensável para qualquer aplicação clínica real.